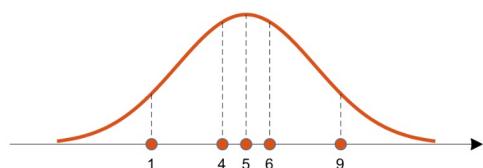
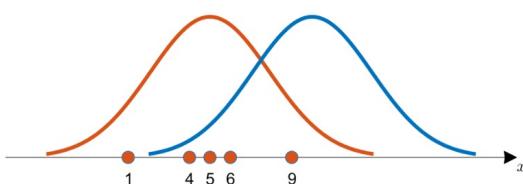


Maximum Likelihood Estimation - MLE



Note) Gaussian Distribution이라고 가정하면,

이때 각각 Parameter μ, σ^2 가 존재하니, 이를 대입해 각각의 확률을 계산해보자.

$$\mu = \frac{(x_1 + x_2 + \dots + x_n)}{n}, \quad \sigma^2 = \sqrt{\frac{(x_1 - \mu)^2 + \dots + (x_n - \mu)^2}{n}}$$

MLE는 위와 같은 Data를 추정 방법이다. \Rightarrow 관측되는 Data를 가장 잘 Modeling하는 Probability Distribution의 Parameter를 찾는 것이다.

\hookrightarrow It: Input Data의 Distribution을 정확히 찾을 수 있다. \Rightarrow 그에 맞는 Parameter를 찾는 것이다.

이제, Sample Data의 Parameter $\theta = (\theta_1, \theta_2, \dots, \theta_m)$ 을 추정하는 방법을 알아보자.

우리는 Data를 얻고, 그에 Data를 더해 Sampling 확률이나 상대적 Distribution의 Property를 Estimation할 수 있다.

이제, Distribution의 어떤 특성을 기준으로, 어떤 Distribution의 Property를 추정하는 것이다.

\hookrightarrow "모수"

Likelihood: 같은 Data가 같은 Distribution으로부터 나온 확률을 계산하는 것이다. (Probability가 같은 상황에 관계가 있는 확률)

\hookrightarrow 이를 계산하기 위해 각 Sample Data의 Conditional Distribution의 어떤 특성을 계산해야 한다.

$$P(z|\theta) = \prod_{k=1}^n P(z_k|\theta) \Rightarrow$$

\hookrightarrow 같은 Data의 Sampling이 무한정으로 이루어지는 Event이다.
즉, 확률.

\hookrightarrow 이 결과가 가장 큰 값을 갖도록 만든다.

$$\text{log scale: } L(\theta|z) = \log P(z|\theta) = \sum_{i=1}^n \log P(z_i|\theta)$$

$$\hookrightarrow \frac{\partial}{\partial \theta_j} L(\theta|z) = \sum_{i=1}^n \frac{\partial}{\partial \theta_j} \log P(z_i|\theta) = 0 \Leftrightarrow \text{Likelihood Function} \Leftrightarrow \text{Maximize the value of it.}$$

Multivariate Gaussian Distribution

$$\rightarrow X \sim N(\mu, \Sigma)$$

Multivariate Gaussian Distribution의 DPF는 어떤 것인가.

$$P(x \mid \mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (x-\mu)^T \Sigma^{-1} (x-\mu) \right]$$

• n : Data Dimension $\rightarrow \frac{1}{\sqrt{(2\pi)^n \cdot |\Sigma|}}$ 를 봄수 알겠.

• μ : Mean

• Σ : Covariance Matrix $\rightarrow X$ 가 Multivariate normal, Σ 의 (i,j)는 $\text{Cov}(X_i, X_j)$ 이다.

$$\begin{aligned} \text{※ } \text{Cov}(x, y) &= E[(x - E[x])(y - E[y])] \\ &= E[xy] - E[x]E[y] \end{aligned}$$

$$\rightarrow \begin{bmatrix} \text{Cov}(x_1, x_1) & \cdots & \text{Cov}(x_1, x_n) \\ \vdots & \ddots & \vdots \\ \text{Cov}(x_n, x_1) & \cdots & \text{Cov}(x_n, x_n) \end{bmatrix} = \begin{bmatrix} E[(x_1 - E[x_1])(x_1 - E[x_1])] & \cdots \\ \vdots & \vdots \\ E[(x_n - E[x_n])(x_n - E[x_n])] & \cdots \end{bmatrix}$$

$$= E \begin{bmatrix} (x_1 - \mu_1)^2 & \cdots & (x_1 - \mu_1)(x_n - \mu_n) \\ \vdots & & \vdots \\ (x_n - \mu_n)(x_1 - \mu_1) & \cdots & (x_n - \mu_n)^2 \end{bmatrix} = E \begin{bmatrix} (x_1 - \mu_1) \\ \vdots \\ (x_n - \mu_n) \end{bmatrix} \begin{bmatrix} (x_1 - \mu_1) & \cdots & (x_n - \mu_n) \end{bmatrix}$$

$$= E[(x - \mu)(x - \mu)^T]$$

Log Scale Multivariable Gaussian Distribution

μ 가 n 차원 벡터 · Σ 는 $n \times n$ 정방행렬

Multivariate Gaussian Distribution의 PDF는 다음과 같다.

$$P(z|\mu, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp \left[-\frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu) \right]$$

$\xrightarrow{\quad}$ $\frac{1}{\sqrt{(2\pi)^n |\Sigma|}}$ 를 놓을 것이다.
 ↓ Determinant.

여기서 Log를 취하면, $\log \left(\frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \right) \log \left(\exp \left[-\frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu) \right] \right)$

$$= \log \left(\frac{1}{\sqrt{(2\pi)^n |\Sigma|}} \right) - \frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu)$$

$$= \log \left(((2\pi)^n |\Sigma|)^{-\frac{1}{2}} \right) - \frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu)$$

$$= -\frac{1}{2} \log ((2\pi)^n |\Sigma|) - \frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu)$$

$$= -\frac{n}{2} \log (2\pi) - \frac{1}{2} \log (|\Sigma|) - \frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu)$$

즉 Dimension에 $-\frac{n}{2} \log (2\pi)$ 과 $-\frac{1}{2} \log (|\Sigma|)$ 은 Constant가 된다.

즉 $-\frac{1}{2} (z-\mu)^T \Sigma^{-1} (z-\mu)$ 은 Random Variable의 확률밀도.

이제 \rightarrow 문제로 보면, $(z-\mu)^T \Sigma^{-1} (z-\mu)$ 을 Minimize하는 방식으로 생각하자.

Levenberg - Marquardt Algorithm [LMA를 학습한다.]

: Non-linear least square을 해결하는 대표적인 방법이다.

↳ Non-linear function optimization의 일종
가장 많이 쓰이는 방법이다.

LMA는 Gauss-Newton Method와 Gradient Descent Method 결합 형태이다.

↳ 이를 알기 쉽게선 이를 이해하기 쉽다.

• 최소화법 : least square method

\Rightarrow 관측값 $(x_i, y_i)_{i=1 \dots n}$, Model parameter $P = (P_1, P_2, \dots P_m)$, Model: $y = f(x, P)$

여기서 관측값과 Model의 차를 r_i 라고 한다.

이때, r_i 가 세종합이 최소가 되도록 하는 Parameter P 를 찾는다.

$$P^* = \operatorname{argmin} \sum_{i=1}^n r_i^2 = \operatorname{argmin} \sum_{i=1}^n (y_i - f(x_i, P))^2$$

* 관측값의 임수가 아으면, r_i^2 에 기울기를 통해 최소화 시킨다.

이는 P 의 어떤 부분이 '0'이 되는 P 를 구하여 풀수 있다.

이여, Model의 linear한지, linear least square, non-linear한지, non-linear least square 판별.

\Rightarrow Non linear인 경우 \Rightarrow Closed form Solution이 \Rightarrow Iterative Minimization을 사용한다.

즉, P 의 일부 부분에 대해 minimize하는 수로 P 를 업데이트한다.

↳ 여기서 Gradient Descent, Gauss Newton,

LMA 방법론이 속한다.

하지만 몇가지 있는 경우, Gradient Descent,

그리고 몇가지 있는 경우, Gauss-Newton을 이용한다

↳ Non-linear Function

기본적으로 Linear Function은
라인처럼 직선으로 흐른다

$$p_{k+1} = p_k - (J_{\Gamma}^T J_{\Gamma} + \mu_k \operatorname{diag}(J_{\Gamma}^T J_{\Gamma}))^{-1} J_{\Gamma}^T r(p_k), k \geq 0$$

$$J_{\Gamma}(p) = \begin{bmatrix} \frac{\partial r_1(p)}{\partial p_1} & \dots & \frac{\partial r_1(p)}{\partial p_m} \\ \vdots & \ddots & \vdots \\ \frac{\partial r_n(p)}{\partial p_1} & \dots & \frac{\partial r_n(p)}{\partial p_m} \end{bmatrix}, r(p) = \begin{bmatrix} r_1(p) \\ r_2(p) \\ \vdots \\ r_n(p) \end{bmatrix} = \begin{bmatrix} y_1 - f(x_1, p) \\ y_2 - f(x_2, p) \\ \vdots \\ y_n - f(x_n, p) \end{bmatrix}$$

Closed - Form Solution

: 일정한 경우 수학 연산으로 해를 구할 수 있는 적을 의미한다.

Non-linear 이지만 미분방정식의 Coefficient가 일정하면 closed-form solution X

Singular Value Decomposition

임의의 $m \times n$ Matrix on 어떤 SVD는 $A = U\Sigma V^T$ 로 정의할 수 있다.

- U 는 $m \times m$ 정방행렬 \rightarrow 정.밀 Vector로 구성, 크기: 1
- V 는 $n \times n$ 정방행렬 $\quad Q^{-1} = Q^T$
 $Q^T Q = I$
- Σ 는 $m \times n$ 정사각 행렬

그리고 U 는 $A A^T$ 를 eigendecomposition \Rightarrow 2nd orthogonal Matrix, U '의 Column Vector \Rightarrow left singular vector

V 는 $A^T A$ 를

"

V 의 " \Rightarrow right singular vector

Σ 는 $A A^T$, $A^T A$ 를 eigendecomposition \Rightarrow 그 eigenvalues를 square Root로 대각 원소로 하는 $m \times n$

행렬 Σ 로 2개의 원소를 A 의 singular value로 한다.

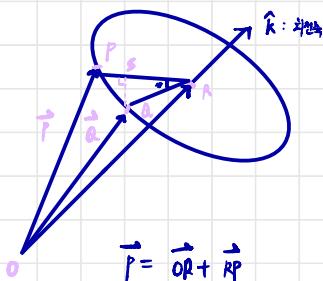
$$\begin{aligned} a &= (a_x, a_y, a_z) = k \\ c &= \cos \alpha \\ s &= \sin \alpha \end{aligned}$$

$$R_s = \begin{bmatrix} (1-c)a_x^2 + c & (1-c)a_x a_y - sa_z & (1-c)a_x a_z + sa_y \\ (1-c)a_x a_y + sa_z & (1-c)a_y^2 + c & (1-c)a_y a_z - sa_x \\ (1-c)a_x a_z - sa_y & (1-c)a_y a_z + sa_x & (1-c)a_z^2 + c \end{bmatrix}$$

Rodrigues Formula

Axis of Angle이 주어질 때, 어떤 Vector를 해당 Axis의 angle θ 에 대한 Angle의 Rotating Vector를 구하는 과정이다.

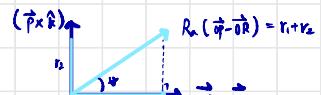
$\vec{OP} - \vec{OR} \in \vec{PR}$ \perp $(\vec{OP} - \vec{OR})$ GJS로 구해낼 수 있다.



$$\begin{aligned} \vec{Q} &= \vec{OR} + \vec{RS} + \vec{SO} \\ &\downarrow \\ &(\vec{P} \cdot \hat{k}) \hat{k} \\ : \vec{P} &\text{은 } \hat{k} \text{의 Injection} \\ \Rightarrow \vec{P} &\text{은 } \hat{k} \text{의 } \perp \end{aligned}$$

$$\therefore R_s(I) = \vec{OR} + R_s(\vec{P} - \vec{OR}) \text{가 된다.}$$

$$\begin{aligned} (\vec{OP} - \vec{OR}) &\perp (\vec{P} \times \hat{k}) \\ \text{이 } \hat{k} \text{의 } \perp \text{인 coordinate } \Rightarrow \\ \Rightarrow \text{ } \hat{k} \text{은 } \text{좌표계를 } \text{인수로}. \end{aligned}$$



$$\|R_s(I)\| = \cos \theta \cdot \|R_s(\vec{P} - \vec{OR})\|$$